



École Centrale Casablanca

Rapport de stage, Mission Assistant Ingénieur (AI), 2026

Surprise syntaxique et surprise neuronale : quelle prévisibilité prédit la durée des mots en parole lue et en parole spontanée ?

*Syntactic versus neural surprisal : which kind of
predictability predicts word duration in read and spontaneous speech ?*



Organisme d'accueil

Laboratoire Parole et Langage (LPL, UMR 7309)
CNRS, Aix-Marseille Université, Aix-en-Provence, France

Élève ingénieure

THABET Nada

Tuteur dans l'organisme d'accueil

Philippe Blache, Directeur de recherche

Période du stage

du 18 mai 2026 au 14 août 2026, prolongé jusqu'au 31 août 2026

Remerciements

Je remercie en premier lieu Monsieur Philippe Blache, Directeur de recherche et mon tuteur au Laboratoire Parole et Langage, pour la confiance qu'il m'a accordée en me confiant un sujet de recherche ouvert, et pour la qualité de son encadrement. Ses questions, souvent plus exigeantes que les réponses que j'apportais, m'ont appris à ne jamais me satisfaire d'un résultat qui « marche » sans en avoir compris le mécanisme. C'est cette exigence qui a orienté la partie la plus intéressante de ma mission.

Je remercie l'ensemble des membres du laboratoire pour leur accueil et leur disponibilité. Les échanges, en réunion d'équipe comme au détour d'un couloir, m'ont permis de comprendre progressivement les usages du domaine : ce qui constitue une donnée exploitable, ce qu'un résultat doit démontrer, et la manière dont une hypothèse se discute collectivement.

Je remercie également le corps professoral de l'École Centrale Casablanca pour la préparation méthodologique qui m'a permis d'aborder ce stage avec une démarche structurée. Enfin, je remercie ma famille et mes camarades de promotion pour leur soutien constant.

Synthèse

Le problème et ses enjeux. La théorie de la *surprisal* (Hale, 2001 ; Levy, 2008) postule que le coût de traitement d'un mot est proportionnel à son improbabilité en contexte. Demberg, Keller et Koller (2012) ont montré que la surprise *syntactique*, calculée à partir de la structure grammaticale, prédit l'allongement des mots en parole lue. Les grands modèles de langue (LLM) fournissent aujourd'hui une prévisibilité bien plus performante en apparence. Le laboratoire souhaitait savoir si cette prévisibilité neuronale remplace la prévisibilité structurale pour expliquer la durée des mots. L'enjeu est théorique : déterminer si l'articulation est modulée par un traitement spécifiquement *grammatical* ou par une prévisibilité globale indifférenciée. La question est née d'un constat d'échec : la surprise des LLM ne donnait pas de résultats convaincants sur les données EEG du laboratoire, ce qui a conduit à décomposer cette grandeur composite plutôt qu'à l'utiliser en bloc.

La démarche. J'ai construit la chaîne permettant d'obtenir une surprise syntaxique fiable. Faute de pouvoir utiliser Whisper, trop lent, j'ai développé un segmenteur prosodique combinant pause, allongement final et reset de pitch, évalué contre le texte original du livre (précision 0,70, rappel 0,84, F_1 0,76, contre 0,83 pour Whisper qui dispose en plus d'un modèle de langue), puis réalisé l'analyse en constituants. J'ai ensuite implémenté la surprise syntaxique incrémentale fondée sur les probabilités de préfixe d'une grammaire probabiliste (Jelinek et Lafferty, 1991 ; Stolcke, 1995), validée contre un calcul exhaustif de référence, puis une surprise LLM par mot avec GPT-2, en réalignant les sous-unités du modèle sur les mots alignés dans le signal. Les deux mesures ont été appliquées à deux corpus opposés : parole lue (*The Old Man and the Sea*, un narrateur, environ 11 000 mots) et parole spontanée (corpus AMI). Chaque mesure a été testée sur la durée en contrôlant longueur, fréquence, interaction longueur $\times$ fréquence, classe du mot, et pour le spontané débit local et locuteur.

Les résultats. En parole lue, la surprise syntaxique conserve un effet positif hautement significatif après contrôle de la fréquence ($+0,00168$ s/bit, $p = 4 \cdot 10^{-10}$) : l'effet de Demberg est répliqué. La surprise LLM perd tout effet ($-0,00022$, $p = 0,27$). Sur la parole spontanée, après appariement strict des deux mesures sur les mêmes 60 285 mots et test en modèle mixte à intercept aléatoire par locuteur, la surprise syntaxique garde un effet positif significatif mais modeste ($+0,00077$, $p = 0,028$), tandis que la surprise LLM présente un coefficient négatif significatif, attribué à un effet de suppression lié à sa forte collinéarité avec la fréquence. Pour expliquer ce contraste, j'ai construit un indicateur, l'*EXTRA*, qui mesure la part du lien surprise-durée non explicable par la fréquence : il est positif pour la mesure syntaxique et quasi nul pour le LLM, ce qui prédit exactement le sort de chaque effet.

Valeur pour l'organisme d'accueil. La mission livre une chaîne de traitement reproductible et évaluée à chaque maillon, deux corpus enrichis mot à mot, des résultats statistiques documentés et une explication mécanique du contraste observé. Le résultat

central est directement exploitable : ce n'est pas la prévisibilité globale d'un modèle de langue, mais la difficulté spécifiquement structurale, qui module la durée des mots au-delà de la fréquence.

Executive Summary

Problem and stakes. Surprisal theory (Hale, 2001; Levy, 2008) predicts that the processing cost of a word is proportional to its improbability in context. Demberg, Keller and Koller (2012) showed that *syntactic* surprisal predicts word lengthening in read speech. Large language models (LLMs) now provide far more accurate predictability estimates. The host laboratory wanted to determine whether this neural predictability supersedes structural predictability in explaining word duration: is articulation modulated by specifically *grammatical* processing, or by undifferentiated global predictability? The question arose from a negative finding: LLM surprisal did not yield convincing results on the laboratory’s EEG data, which led us to decompose this composite quantity rather than use it as a whole.

Approach. I built the pipeline required for reliable syntactic surprisal: segmentation of TextGrid files into linguistic units, objective evaluation of that segmentation against the original book text (precision, recall, F_1), and constituency parsing. I then implemented true incremental syntactic surprisal based on probabilistic context-free grammar prefix probabilities (Jelinek and Lafferty, 1991; Stolcke, 1995), validated against an exhaustive reference computation, and word-level LLM surprisal with GPT-2, realigning the model’s subword units onto the words aligned in the speech signal. Both measures were applied to two contrasting corpora: read speech (*The Old Man and the Sea*, single narrator, about 11,000 words) and spontaneous speech (AMI meeting corpus). Each was tested against word duration while controlling for word length, lexical frequency, the length $\times$ frequency interaction, word class, and, for spontaneous speech, local speech rate and speaker identity.

Results. In read speech, syntactic surprisal retains a positive, highly significant effect after frequency control ($+0.00168$ s/bit, $p = 4 \cdot 10^{-10}$), replicating Demberg’s effect, whereas LLM surprisal shows no remaining effect (-0.00022 , $p = 0.27$). In spontaneous speech, after strictly matching both measures on the same 60,285 words and fitting a mixed-effects model with a random intercept per speaker, syntactic surprisal retains a positive but modest significant effect ($+0.00077$, $p = 0.028$), whereas LLM surprisal shows a significant negative coefficient, interpreted as a suppression effect caused by its high collinearity with frequency. To explain this contrast, I designed an indicator, the *EXTRA*, quantifying the part of the surprisal–duration relationship that frequency cannot account for. It is positive for the syntactic measure and virtually null for the LLM measure, which exactly predicts the fate of each effect.

Value delivered. The mission delivers a reproducible pipeline validated at each step, two word-level enriched corpora, documented statistical results, and a mechanistic explanation of the observed contrast. The central finding is directly usable: it is not the global predictability of a language model, but specifically structural difficulty, that modulates word duration beyond frequency.

Table des matières

Remerciements	1
Synthèse (Executive Summary)	2
Executive Summary (English)	4
Chapitre 1 Introduction et reformulation du problème	7
1.1 Contexte scientifique	7
1.2 L'organisme d'accueil et les enjeux	7
1.3 État de l'art	8
1.4 Genèse : de l'EEG à la décomposition de la surprise	8
1.5 Reformulation du problème et objectifs	9
Chapitre 2 Intégration dans l'environnement professionnel	10
2.1 Prise de poste et compréhension de l'organisation	10
2.2 Parties prenantes et experts consultés	11
2.3 Organisation du travail	11
Chapitre 3 Approche, méthodes et justification des choix	12
3.1 Les deux corpus	12
3.2 Segmentation du corpus et évaluation du segmenteur	13
3.3 L'analyse en constituants	15
3.4 Mesure 1 : la surprise syntaxique incrémentale	16
3.5 Mesure 2 : la surprise neuronale (GPT-2)	16
3.6 Variable expliquée et variables de contrôle	17
3.7 Modèles statistiques et construction des figures	17
Chapitre 4 Situations problématiques clés	18
4.1 Situation 1 : un effet inversé et le choix du modèle	18
4.2 Situation 2 : pourquoi la fréquence détruit un effet et pas l'autre, l'EXTRA	19
4.3 Situation 3 : un défaut d'appariement détecté tardivement . . .	22
4.4 Ressources mobilisées et organisation face à ces situations . . .	23
Chapitre 5 Résultats obtenus	23
5.1 Parole lue	24
5.2 Parole spontanée	25
5.3 Comparaison des corpus	27
5.4 Validité, nouveauté et utilité	29
5.5 Limites	30

Chapitre 6	Prolongements possibles	30
Chapitre 7	Bilan des apprentissages professionnels	31
Conclusion		32
Bibliographie		34
Annexe A	Chaîne de traitement et livrables logiciels	36
Annexe B	Formulation des modèles statistiques	36
Annexe C	Résultats détaillés	36
Annexe D	Périmètre des données analysées	38

Chapitre 1

Introduction et reformulation du problème

Ce chapitre situe la mission dans son contexte scientifique, présente l’organisme d’accueil et les enjeux, dresse l’état de l’art, retrace la genèse du sujet à partir d’un constat d’échec sur les données EEG, et aboutit à la reformulation du problème qui a structuré tout le travail.

1.1 Contexte scientifique

Lorsqu’une personne parle, elle ne prononce pas tous les mots avec la même durée. Une partie de cette variation s’explique par des facteurs mécaniques : un mot long contient plus de phonèmes, un mot fréquent est produit plus rapidement. Mais une question plus profonde se pose : au-delà de ces facteurs, la *difficulté de traitement* du mot laisse-t-elle une trace mesurable dans sa durée ?

La psycholinguistique computationnelle a formalisé cette idée par la notion de *surprise*. Introduite par Hale (2001) et développée par Levy (2008), elle postule que le coût cognitif de traitement d’un mot est proportionnel à son improbabilité dans le contexte qui le précède :

$$\text{surprise}(w_k) = -\log_2 P(w_k \mid w_1 \dots w_{k-1}) \quad (1)$$

Un mot attendu a une probabilité proche de 1, donc une surprise proche de 0 bit ; un mot inattendu a une surprise élevée. L’unité, le bit, vient de la théorie de l’information : la surprise est la quantité d’information apportée par le mot.

Demberg, Keller et Koller (2012) ont établi un résultat plus spécifique : la surprise calculée à partir de la *structure syntaxique* prédit l’allongement des mots en parole lue, indépendamment des autres facteurs. Un mot dont l’intégration grammaticale est coûteuse est physiquement articulé plus longuement. Depuis, les grands modèles de langue estiment la probabilité d’un mot avec une précision sans commune mesure avec les grammaires probabilistes. D’où la question qui m’a été confiée : puisque le LLM prédit mieux les mots, prédit-il mieux la durée, et la difficulté syntaxique conserve-t-elle une utilité propre ?

1.2 L’organisme d’accueil et les enjeux

Le Laboratoire Parole et Langage (LPL, UMR 7309) est une unité mixte de recherche du CNRS et d’Aix-Marseille Université. Il réunit linguistes, phonéticiens, informaticiens, psychologues et neuroscientifiques autour de la parole et du langage, étudiés dans leur dimension formelle comme dans leur réalisation physique et cérébrale. Cette pluridisciplinarité conditionne la manière dont un résultat est jugé recevable : une conclusion doit tenir du point de vue linguistique, du point de vue du signal et du point de vue statistique.

L’enjeu de ma mission est théorique, ce qui est cohérent avec une unité de recherche. Il s’agissait de trancher une question conditionnant des choix de modélisation futurs : faut-

il continuer à construire des mesures de difficulté syntaxique, coûteuses à produire et à valider, alors qu’un modèle neuronal généraliste fournit une prévisibilité immédiatement disponible ? Si le LLM suffit, une partie de l’effort de modélisation grammaticale devient redondante. Sinon, la durée est sensible à une dimension spécifiquement structurale, qui mérite d’être modélisée pour elle-même. Un enjeu secondaire portait sur la généralisation : le résultat de Demberg a été obtenu en parole lue, situation très contrôlée, et rien ne garantissait qu’il tienne en conversation spontanée.

1.3 État de l’art

Quatre familles de travaux structurent le problème. Sur le plan théorique, Hale (2001) propose la surprisal comme mesure du coût de traitement incrémental et montre qu’elle rend compte des difficultés observées sur les ambiguïtés locales ; Levy (2008) en donne une justification plus générale, la surprise correspondant à la réallocation de croyance qu’un auditeur doit effectuer en recevant un mot. La surprise n’est donc pas un simple indicateur statistique : la théorie lui attribue une signification cognitive.

Sur le plan algorithmique, calculer la surprise à partir d’une grammaire suppose d’évaluer la probabilité d’un *préfixe* de phrase, c’est-à-dire la somme des probabilités de toutes les analyses compatibles avec les mots vus. Jelinek et Lafferty (1991) puis Stolcke (1995) ont défini les algorithmes rendant ce calcul possible pour une grammaire hors-contexte probabiliste, notamment par la gestion de la fermeture du coin gauche. La surprise incrémentale s’obtient comme rapport de deux probabilités de préfixe successives :

$$\text{surprise}(w_k) = -\log_2 \frac{P(w_1 \dots w_k)}{P(w_1 \dots w_{k-1})} \quad (2)$$

Sur les déterminants de la durée, Aylett et Turk (2004) ont formulé l’hypothèse de la *Smooth Signal Redundancy* : plus un mot est prévisible ou fréquent, plus il est réduit dans le signal. Bell et al. (2003, 2009) ont établi l’influence du débit, de la position dans l’énoncé et de la classe du mot. Ces travaux définissent la liste des contrôles obligatoires de toute étude sur la durée.

Enfin, l’usage des LLM comme estimateurs de prévisibilité s’est généralisé depuis Radford et al. (2019). Leur avantage est une qualité prédictive supérieure ; leur limite, ici décisive, est que leur prévisibilité est *indifférenciée* : elle mélange sémantique, syntaxe, collocations et fréquence, sans qu’on puisse isoler la contribution grammaticale.

1.4 Genèse : de l’EEG à la décomposition de la surprise

La mission, telle qu’elle figure sur ma fiche descriptive, s’inscrivait dans un travail plus large du laboratoire portant sur la relation entre prévisibilité des mots et réponses cérébrales enregistrées par électroencéphalographie (EEG). L’idée était classique : si la surprise reflète un coût de traitement, elle doit se retrouver dans les signaux cérébraux.

C’est un constat négatif qui a réorienté le travail. Les analyses menées avec la surprise

issue des modèles de langue ne donnaient pas de résultats convaincants sur les données EEG. Plutôt que d’accumuler des variantes du même modèle, une question de fond a été posée : que mesure exactement la surprise d’un LLM ? La réponse a déterminé toute la suite. Cette surprise est une grandeur *composite* : elle agrège en un seul nombre la prévisibilité syntaxique, la prévisibilité sémantique, les collocations et la fréquence lexicale. Si cette grandeur échoue à expliquer un signal, deux interprétations restent ouvertes : soit aucune de ses composantes n’a d’effet, soit certaines en ont un et sont noyées par les autres. Un nombre unique ne permet pas de trancher.

La stratégie retenue avec mon tuteur a donc été de **décomposer la surprise** et de commencer par sa composante syntaxique, calculée explicitement à partir de la structure grammaticale. Cette composante a un avantage décisif : elle est construite, donc interprétable. Ce choix explique la chronologie du stage. Il a fallu d’abord construire, au mois de juin, toute la chaîne donnant une surprise syntaxique fiable : segmenter le corpus en unités linguistiques, valider cette segmentation, puis réaliser l’analyse en constituants dont la surprise est dérivée (sections 3.2 et 3.3). La comparaison avec la surprise des LLM n’a pu être menée qu’ensuite, sur une base validée.

1.5 Reformulation du problème et objectifs

La question initiale était une question de comparaison : « la surprise LLM fait-elle mieux que la surprise syntaxique pour prédire la durée ? ». L’analyse des premiers résultats m’a conduite à la reformuler, car telle quelle elle appelait une réponse trompeuse. Si l’on compare la capacité brute des deux mesures, le LLM l’emporte nettement. Mais cette victoire est vide de sens : la surprise LLM est très fortement corrélée à la fréquence lexicale, déterminant connu et massif de la durée. Le LLM « gagne » largement parce il redit la fréquence.

Reformulation retenue. Une fois neutralisés les déterminants connus de la durée (longueur, fréquence, classe du mot, et pour le spontané débit et locuteur), quelle mesure de prévisibilité conserve un effet propre sur la durée du mot ? Et par quel mécanisme une mesure conserve-t-elle son effet alors que l’autre le perd ?

Quatre objectifs opérationnels en découlent : **(1)** construire une chaîne fiable pour la composante syntaxique, de la segmentation évaluée jusqu’à un calcul de surprise incrémentale exact et validé ; **(2)** calculer une surprise LLM par mot, correctement alignée sur les mots segmentés dans le signal ; **(3)** produire la comparaison systématique des deux mesures quant à leur effet sur la durée, avec des contrôles rigoureux et sur deux corpus de nature opposée, objectif central de la fiche de mission et objet du compte rendu de comparaison ; **(4)** expliquer le contraste observé, et non se contenter de le constater. Ce quatrième objectif n’était pas dans la demande initiale : il est né d’une objection apparue en produisant la comparaison (section 4.2).

En clôture de ce chapitre. Le problème posé est donc passé d’une question de performance comparée à une question d’effet propre, et la stratégie retenue consiste à décomposer

une grandeur composite plutôt qu'à l'utiliser en bloc. Avant de détailler la méthode, le chapitre suivant décrit le cadre dans lequel ce travail a été mené, car les choix scientifiques qui suivent sont indissociables du fonctionnement du laboratoire et des personnes qui y ont contribué.

Chapitre 2

Intégration dans l'environnement professionnel

Ce chapitre décrit la prise de poste dans une unité de recherche, les parties prenantes sollicitées et l'effet concret de ces échanges sur le travail, puis l'organisation de la mission en six phases.

2.1 Prise de poste et compréhension de l'organisation

Un laboratoire ne fonctionne pas comme une entreprise de production. Il n'y a pas de cahier des charges figé au démarrage ni de spécification détaillée du livrable : le sujet se précise à mesure que les résultats arrivent. Ce qui m'a d'abord semblé un manque de cadrage s'est révélé être le mode de fonctionnement normal d'une activité de recherche, où la formulation du problème fait partie du travail. La première semaine, consacrée à la lecture de Demberg et al. (2012) et à la prise en main des données, m'a fait comprendre que la difficulté centrale ne serait pas algorithmique mais méthodologique : produire un nombre est facile, démontrer que ce nombre signifie quelque chose est bien plus long.

La seconde leçon a porté sur les critères d'évaluation. En contexte industriel, un livrable est jugé sur sa conformité à une spécification ; en laboratoire, il est jugé sur sa *défendabilité*. La question posée à chaque présentation n'est pas « est-ce que ça fonctionne ? » mais « comment sais-tu que c'est vrai, et quelle explication alternative as-tu écartée ? ». J'ai adapté ma manière de travailler en documentant l'origine de chaque chiffre et en préparant, pour chaque résultat, l'objection la plus probable.

2.2 Parties prenantes et experts consultés

Table 1 – *Parties prenantes et nature des sollicitations.*

Partie prenante		Rôle	Sollicitation
Philippe (tuteur)	Blache	Cadrage théorique, validation scientifique	Points d’avancement, arbitrages sur la méthode et la reformulation du problème
Chercheurs du signal		Alignement mot/signal, plausibilité des durées	Critères de filtrage des durées aberrantes, traitement des disfluences
Linguistes formels		Validité de l’analyse syntaxique	Définition des mots de contenu, limites du passage automatique
Chercheur en neuro-imagerie langage	en du	Mise en relation des indices de surprise avec le signal EEG	Transmission des indices calculés sur <i>The Old Man and the Sea</i> et cadrage des formats attendus
Doctorante de l’équipe	de	Contrôle des résultats et analyse du contenu informationnel de la surprise LLM	Relecture critique des analyses et discussion sur la part syntaxique et sémantique
Équipe du laboratoire		Regard critique collectif	Présentations d’avancement ayant conduit à des vérifications supplémentaires

Ces échanges ont eu un effet concret. Une remarque sur la parole spontanée m’a conduite à ajouter le contrôle du débit local, absent de ma première version : sans lui, la variabilité du débit noyait l’effet recherché sur AMI. De même, la discussion sur le statut des disfluences (« uh », « um », « yeah ») m’a amenée à les exclure, ces éléments n’étant pas des mots au sens grammatical et leur durée obéissant à une logique différente.

2.3 Organisation du travail

La mission s’est déroulée en six phases séparées par des points de validation.

Phase 1 (mi-mai). Appropriation de l’état de l’art, prise en main des données EEG et du corpus lu, décision de décomposer la surprise et de partir de sa composante syntaxique.

Phase 2 (juin) : construction de la chaîne syntaxique. Cette phase, la plus longue de la mission, a d’abord porté sur le développement d’un segmenteur prosodique, après l’abandon de Whisper jugé trop lent, puis sur son évaluation contre le texte original du livre (précision 0,70, rappel 0,84, F_1 0,76). Elle s’est poursuivie par l’analyse en constituants, l’implémentation du calcul de surprise incrémentale et sa validation contre une énumération exhaustive.

Phase 3 (juillet). Chaîne complète sur la parole lue, extension au corpus AMI avec les contrôles propres au spontané, calcul de la surprise GPT-2 sur les deux corpus.

Phase 4 (début août) : la comparaison systématique, livrable principal de la

mission. Cette phase correspond à l’objet central défini par ma fiche de mission : comparer la surprise syntaxique et la surprise LLM quant à leur effet sur la durée des mots. Elle a donné lieu au compte rendu de comparaison, construit selon une progression identique pour chaque corpus : durées brutes d’abord, durées après contrôle ensuite, puis effet spécifique du contrôle de la fréquence, avant une comparaison croisée des deux corpus mesure par mesure. Ce document rassemble l’ensemble des figures et des coefficients, chaque figure étant accompagnée de son analyse. Il constitue le livrable de référence de la mission et la base à partir de laquelle tout le reste a été construit.

Phase 5 (mi-août) : explication du contraste et consolidation. C’est en produisant la comparaison qu’est apparue l’objection à l’origine de l’indicateur EXTRA, développé dans un document dédié. Cette phase a également porté sur la vérification systématique de la cohérence entre figures et données, qui a révélé le défaut d’appariement sur AMI, sa correction et le passage au modèle mixte, puis la mise à jour des deux comptes rendus.

Phase 6 (fin août) : valorisation des résultats. Le stage ayant été prolongé jusqu’au 31 août, cette dernière phase est consacrée à la valorisation scientifique du travail. Elle comprend la préparation des indices de surprise calculés sur *The Old Man and the Sea* en vue de leur utilisation comme prédicteurs du signal EEG par l’équipe de neuro-imagerie, et la rédaction, en anglais, de l’article reprenant ces résultats.

Le suivi s’est fait par comptes rendus écrits déposés au fil de l’eau, accompagnés des figures et des scripts permettant de régénérer chaque chiffre. Ce choix de documenter en continu a permis des corrections précoces et m’a évité de reconstituer a posteriori l’origine de valeurs produites plusieurs semaines auparavant.

En clôture de ce chapitre. L’intégration dans un laboratoire s’est donc jouée moins sur la maîtrise technique que sur l’adoption d’un critère de qualité différent, celui de la défendabilité d’un résultat, et sur la capacité à solliciter les bonnes compétences au bon moment. Le chapitre suivant expose la démarche scientifique construite dans ce cadre.

Chapitre 3

Approche, méthodes et justification des choix

Ce chapitre décrit la chaîne de traitement dans l’ordre où elle a été construite : les deux corpus et leur préparation, la segmentation du signal en unités linguistiques et son évaluation, l’analyse en constituants, puis les deux mesures de surprise, les variables de contrôle et enfin les modèles statistiques. Chaque décision méthodologique est présentée avec l’alternative écartée, car c’est cette comparaison qui justifie la validité des résultats.

3.1 Les deux corpus

Travailler sur deux corpus opposés était délibéré : un résultat obtenu sur un seul style de parole peut tenir à une particularité du corpus plutôt qu’à un mécanisme général.

Le premier est le corpus ds004408 (OpenNeuro), enregistrement lu de *The Old Man and the Sea*, réparti en 20 fichiers TextGrid alignés mot à mot, soit environ 11 000 mots après nettoyage. Ses propriétés en font un cas de référence : narrateur unique, donc pas de variabilité inter-locuteurs ; débit régulier ; texte préparé, donc pas de disfluences. C’est aussi la configuration la plus proche de celle de Demberg et al. (2012).

Le second est le corpus AMI, enregistrements de réunions de travail en anglais à plusieurs participants. Il cumule les difficultés absentes de la parole lue : locuteurs aux rythmes très différents, chevauchements, hésitations, énoncés courts et incomplets. C’est pour cela qu’il constitue un test exigeant de la généralisation. Sa préparation a demandé trois décisions explicites. Les **disfluences** (« uh », « um », « hmm », « yeah », « okay » et variantes) ont été retirées : ce ne sont pas des mots au sens grammatical et leur durée relève de la gestion du tour de parole. Les **énoncés de moins de quatre mots** ont été écartés, faute de contexte exploitable pour une surprise incrémentale. Enfin, seules les **durées comprises entre 0 et 2 secondes** ont été retenues, sur les deux corpus : au-delà, il s’agit presque toujours d’une erreur d’alignement. L’analyse finale porte sur 60 285 mots produits par 48 locuteurs sur 12 réunions, périmètre justifié en section 4.3.

3.2 Segmentation du corpus et évaluation du segmenteur

Le corpus lu est fourni en fichiers TextGrid, format d’annotation temporelle où chaque mot porte son instant de début et de fin. C’est ce qu’il faut pour mesurer des durées, mais pas pour calculer une surprise syntaxique : une analyse syntaxique s’applique à une *phrase*, or un TextGrid ne contient ni ponctuation, ni majuscules, ni frontière de phrase. Sans reconstruction des unités linguistiques, l’analyseur recevrait des séquences arbitraires et les probabilités de préfixe n’auraient aucun sens, la surprise d’un mot dépendant entièrement de la phrase où il s’insère. La première tâche de la mission a donc été d’écrire un script de segmentation.

Le choix de développer un segmenteur. La première option envisagée était d’utiliser Whisper, un système de transcription automatique qui restitue une ponctuation. Elle a été abandonnée pour une raison pratique : le temps de traitement était prohibitif à l’échelle du corpus. La décision a donc été prise de développer une segmentation propre, fondée non pas sur une transcription mais directement sur la *prosodie* du signal, c’est-à-dire sur la manière dont la voix marque les fins de phrase.

Principe : trois indices prosodiques combinés. Un locuteur signale une frontière de phrase par plusieurs indices simultanés, et le segmenteur les exploite conjointement. La **pause** qui suit le mot : les silences de fin de phrase sont plus longs que les silences internes. L’**allongement final** : le dernier phonème avant une frontière est étiré, phénomène bien documenté en phonétique. Le **reset de pitch** : la hauteur de la voix, qui descend au fil de la phrase, remonte au début de la suivante ; cette valeur est extraite du signal acoustique à l’aide de la bibliothèque parselmouth.

Ces trois indices n’étant pas exprimés dans la même unité, une pause en secondes n’étant

pas comparable à une hauteur en hertz, chacun est normalisé en score z , c'est-à-dire ramené à un écart à sa propre moyenne exprimé en écarts-types. Ils deviennent ainsi additionnables et sont combinés en un score unique de frontière. Une couche de règles morphosyntaxiques corrige ensuite les frontières impossibles, par exemple une coupure entre un déterminant et son nom. L'approche s'inspire des travaux de segmentation prosodique de Shriberg et Stolcke.

Évaluation. Ce corpus présente un avantage rare : il correspond à un texte publié, dont la version écrite comporte une ponctuation, donc des frontières de phrase *vraies*. J'ai donc aligné la suite de mots du TextGrid sur le texte original, puis comparé position par position les frontières proposées aux frontières réelles. Trois cas apparaissent : frontière proposée et réelle (vrai positif, VP), proposée mais inexistante (faux positif, FP), réelle mais manquée (faux négatif, FN), d'où les trois métriques standard :

$$\text{Précision} = \frac{VP}{VP + FP}, \quad \text{Rappel} = \frac{VP}{VP + FN}, \quad F_1 = 2 \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}} \quad (3)$$

Le F_1 a été retenu comme critère principal parce que les deux fautes dégradent l'analyse en aval de manière différente : un découpage excessif prive le parseur de contexte et gonfle la surprise des premiers mots de chaque fragment, tandis qu'une fusion de phrases produit des structures ingrammaticales inanalysables. Il fallait donc un compromis équilibré, non maximiser une seule métrique.

Résultats. Sur l'alignement mot à mot avec une tolérance de ± 1 mot, le segmenteur prosodique atteint une **précision de 0,70**, un **rappel de 0,84** et un **F_1 de 0,76**.

Ces valeurs prennent tout leur sens comparées à celles de Whisper, écarté au départ pour sa lenteur mais utilisable comme point de comparaison sur un échantillon.

Table 2 – Évaluation du segmenteur contre les frontières du texte original, et comparaison avec Whisper.

Méthode	Précision	Rappel	F_1
Segmenteur développé (prosodie seule)	0,70	0,84	0,76
Whisper (transcription + modèle de langue)	0,79	0,88	0,83

Lecture de ces résultats. Le segmenteur pose 780 frontières là où Whisper en pose 725, pour 653 frontières réelles : il découpe donc un peu trop, ce qui explique sa précision plus faible, mais il en manque peu, d'où un rappel élevé. Ce profil est le bon pour la suite : mieux vaut une frontière superflue, qui produit un segment court mais analysable, qu'une frontière manquée, qui fusionne deux phrases en une structure ingrammaticale.

L'écart avec Whisper s'explique par une différence de nature et non de qualité d'implémentation : Whisper s'appuie sur un modèle de langue, donc sur le contenu lexical, tandis que le segmenteur n'utilise que le signal acoustique. Obtenir un F_1 de 0,76 à partir de la

seule prosodie, contre 0,83 avec l'aide d'un modèle de langue, est un résultat satisfaisant, et le gain en temps de traitement rendait cette approche seule praticable à l'échelle du corpus.

Cette étape conditionne tout ce qui suit : sans elle, une erreur systématique de segmentation se serait propagée silencieusement dans toutes les surprises calculées, sans qu'aucun signe visible ne l'indique. C'est la première application du principe qui a structuré la mission : valider chaque maillon avant de construire le suivant.

3.3 L'analyse en constituants

Les phrases reconstituées, il fallait leur associer une structure. L'analyse retenue est l'analyse *en constituants*, qui décrit une phrase comme un emboîtement de groupes. Dans « the old man caught a big fish », elle identifie un groupe nominal sujet (« the old man ») et un groupe verbal (« caught a big fish »), lui-même contenant un verbe et un second groupe nominal. La phrase devient un arbre dont les nœuds sont des catégories syntaxiques et les feuilles des mots.

Ce choix ne va pas de soi : l'alternative était une analyse en *dépendances*, reliant directement les mots par des relations grammaticales sans groupes intermédiaires. Deux raisons ont motivé les constituants. La première est théorique : l'hypothèse testée porte sur le coût de *construction structurale*, c'est-à-dire ouvrir un constituant, le maintenir en mémoire et le fermer au bon endroit, notion directement représentée dans un arbre de constituants et seulement implicite en dépendances. La seconde est formelle : la surprise incrémentale de Hale (2001) s'appuie sur une grammaire hors-contexte probabiliste, qui est précisément un formalisme de constituants.

Probabilisation. Une analyse devient exploitable pour la surprise lorsqu'elle est probabilisée. Une grammaire hors-contexte probabiliste (PCFG) associe une probabilité à chaque règle de réécriture, estimée sur un corpus arboré. La règle réécrivant une phrase en groupe nominal suivi d'un groupe verbal est très probable ; une construction rare reçoit une probabilité faible. La probabilité d'un arbre est le produit des probabilités des règles employées, $P(\text{arbre}) = \prod_r P(r)$. C'est ce qui transforme une description grammaticale en mesure d'attente : un mot compatible uniquement avec des règles peu probables est syntaxiquement surprenant.

Difficultés. Quatre obstacles ont occupé une part importante du mois de juin. La *couverture lexicale* : les mots absents du vocabulaire de la grammaire font échouer l'analyse de toute la phrase, d'où un traitement des inconnus fondé sur leur catégorie grammaticale. La *récurtivité à gauche* : présente dans les grammaires réalistes, elle fait boucler un analyseur naïf et impose la gestion explicite de la fermeture du coin gauche. Le *coût de calcul* : le nombre d'analyses croît très vite avec la longueur, rendant l'énumération impraticable et imposant des sommes de probabilités calculées incrémentalement. L'*ambiguïté syntaxique* enfin : une phrase admet souvent plusieurs analyses valides, notamment pour le rattachement des groupes prépositionnels. Ce n'est pas un défaut à corriger, c'est précisément

l’ambiguïté qui produit une partie du coût mesuré ; la méthode ne choisit donc pas une analyse mais somme les probabilités de toutes les analyses compatibles.

3.4 Mesure 1 : la surprise syntaxique incrémentale

Une approche plus simple aurait consisté à approcher la surprise syntaxique par la probabilité de la catégorie grammaticale du mot, ou par un n-gramme sur les catégories. Je l’ai écartée après discussion avec mon tuteur : une telle approximation ne mesure pas la difficulté d’*intégration structurale*, cœur de l’hypothèse de Demberg, mais seulement la prévisibilité d’une étiquette.

J’ai donc implémenté la surprise incrémentale véritable. À chaque mot, l’algorithme maintient l’ensemble des analyses partielles compatibles avec le début de phrase lu et somme leurs probabilités :

$$P(w_1 \dots w_k) = \sum_{t \in \mathcal{T}(w_1 \dots w_k)} P(t) \quad (4)$$

où $\mathcal{T}$ désigne l’ensemble des analyses compatibles avec le préfixe. L’implémentation suit Jelinek et Lafferty (1991) et Stolcke (1995), avec la fermeture du coin gauche nécessaire aux règles récursives à gauche.

Validation. Un calcul de probabilité de préfixe est difficile à déboguer : une erreur ne produit pas un plantage mais un nombre plausible et faux. J’ai donc validé par comparaison exhaustive, sur des phrases courtes où il est possible d’énumérer *toutes* les analyses par force brute, la probabilité de préfixe de l’algorithme incrémental face à la somme obtenue par énumération complète. Les deux valeurs coïncident. Sans cette vérification, tous les résultats auraient reposé sur une implémentation non contrôlée.

3.5 Mesure 2 : la surprise neuronale (GPT-2)

La surprise LLM est obtenue avec GPT-2, qui fournit à chaque étape une distribution de probabilité sur l’élément suivant. Une difficulté technique devait être traitée : GPT-2 ne travaille pas sur des mots mais sur des *sous-unités* lexicales issues d’un découpage BPE, un mot rare pouvant être découpé en plusieurs morceaux, alors que mes durées sont définies au niveau du mot aligné dans le signal. J’ai donc implémenté un réalignement : pour chaque mot, on identifie les sous-unités qui le composent et l’on somme leurs surprises, conséquence directe de la composition des probabilités conditionnelles :

$$\text{surprise}(\text{mot}) = \sum_{i \in \text{sous-unités}} -\log_2 P(u_i \mid u_1 \dots u_{i-1}) \quad (5)$$

Sans cette étape, la mesure aurait été décalée par rapport aux durées, donc dépourvue de sens. Un test complémentaire a par ailleurs été mené avec un modèle conversationnel (DialoGPT) sur la parole spontanée, afin de vérifier si le comportement anormal observé sur AMI tenait à l’inadéquation du domaine d’entraînement, GPT-2 étant entraîné majo-

ritairement sur de l'écrit.

3.6 Variable expliquée et variables de contrôle

La variable expliquée est la durée du mot, différence entre instant de fin et instant de début. Contrôler un facteur signifie l'introduire dans le modèle pour ne comparer que des mots équivalents sur ce facteur ; chaque contrôle répond à une objection précise.

Table 3 – *Variables de contrôle, objection neutralisée et source.*

Contrôle	Objection neutralisée	Source
Longueur du mot	Un mot long dure mécaniquement plus longtemps	Demberg et al. (2012)
Fréquence (Zipf)	Un mot rare est à la fois plus surprenant et plus long	van Heuven et al. (2014); Aylett et Turk (2004)
Longueur $\times$ fréquence	L'effet de la longueur dépend de la fréquence	Demberg et al. (2012)
Classe (contenu / outil)	Les mots de contenu sont plus articulés que les mots-outils	Bell et al. (2009)
Débit local (AMI)	Si le locuteur parle vite, tous ses mots sont courts	Bell et al. (2003)
Locuteur (AMI, aléatoire)	Certaines personnes parlent lentement par nature	Baayen et al. (2008); Barr et al. (2013)

La fréquence est mesurée sur l'échelle Zipf, logarithmique : environ 7,7 pour *the*, environ 2 pour un mot rare. Ce choix n'est pas cosmétique, l'effet de la fréquence sur la durée étant lui-même logarithmique ; une échelle linéaire produirait un contrôle mal spécifié. Le débit local est défini pour chaque énoncé comme le nombre de mots divisé par sa durée. Ce contrôle s'est révélé indispensable sur AMI : sans lui, la variance des changements de rythme masquait l'effet recherché.

3.7 Modèles statistiques et construction des figures

Pour la mesure syntaxique, j'ai suivi la méthode en deux étapes de Demberg : régresser la durée sur les contrôles, extraire le résidu, puis examiner son lien avec la surprise. Pour la mesure LLM, cette méthode s'est révélée inadaptée (section 4.1) : la surprise LLM est si corrélée à la fréquence qu'un traitement séquentiel produit une estimation instable. J'ai donc retenu pour les tests un *modèle joint*, estimant simultanément la surprise et tous les contrôles, l'effet propre se lisant directement sur le coefficient de la surprise.

En parole lue, un narrateur unique produit tous les mots : une régression ordinaire convient. Sur AMI, les mots sont regroupés par locuteur et se ressemblent au sein d'une même personne ; traiter 60 285 mots comme indépendants surestimerait l'information disponible et produirait des tests trop optimistes. J'ai donc utilisé un *modèle mixte* à intercept

aléatoire par locuteur, noté (1 | locuteur) : chaque locuteur reçoit sa durée de base, et l'effet de la surprise est estimé une fois cette base retirée.

Lecture des figures. Toutes suivent le même principe. Les mots sont triés par surprise croissante puis répartis en dix groupes de taille égale, les *déciles*. Chaque point représente un décile : abscisse, sa surprise moyenne en bits ; ordonnée, sa durée moyenne en secondes ; barre verticale, l'erreur standard de cette moyenne. La droite est la tendance générale et sa pente, en légende, résume l'effet. Les panneaux **bleus** montrent la durée brute, qui mélange surprise, longueur et fréquence ; les panneaux **rouges** montrent la durée *résiduelle*, dont l'effet des contrôles a été retiré, donc centrée sur zéro. Les pentes affichées sont descriptives : la conclusion statistique repose sur les coefficients des modèles, leur p-value et leur intervalle de confiance (voir le Chapitre 5). Le détail des modèles est donné en Annexe B et le périmètre exact des données en Annexe C.

En clôture de ce chapitre. La chaîne construite va du signal aligné jusqu'aux coefficients testés, avec une vérification à chaque maillon : segmentation évaluée contre le texte original, calcul de surprise validé contre une énumération exhaustive, contrôles issus de la littérature de référence, et modèle statistique adapté à la structure de chaque corpus. C'est cette succession de validations, plus que le choix d'un outil particulier, qui autorisera à lire les résultats comme des effets propres et non comme des artefacts. Le chapitre suivant montre que ce cadre n'a pas été appliqué mécaniquement : il a fallu le corriger en cours de route, à trois reprises.

Chapitre 4

Situations problématiques clés

Ce chapitre détaille les trois moments où la mission a réellement buté sur un obstacle, et la manière dont chacun a été levé : un effet inversé imputable à la méthode d'estimation, une objection théorique restée sans réponse, et un défaut d'appariement détecté tardivement. Une dernière partie recense les ressources mobilisées et l'organisation adoptée face à ces blocages. Ces épisodes, plus que le déroulement nominal, rendent compte du travail réellement fourni.

4.1 Situation 1 : un effet inversé et le choix du modèle

Le symptôme. Lors des premiers tests de la surprise LLM, la durée des mots *diminuait* nettement quand la surprise augmentait : plus un mot était inattendu pour GPT-2, plus il était prononcé rapidement. Ce résultat contredit frontalement la théorie de la surprisal et mes propres résultats syntaxiques sur le même corpus. Deux réactions étaient possibles, toutes deux fautives : accepter le résultat comme une découverte, ou l'écarter comme une anomalie. J'ai fait l'hypothèse d'un problème de méthode d'estimation et cherché à le démontrer.

Le diagnostic. La surprise LLM est extrêmement corrélée à la fréquence, bien plus que

la surprise syntaxique : en parole lue, $r = -0,75$ contre $r = -0,53$. En variance partagée, 56 % de la variance de la surprise LLM est déjà contenue dans la seule fréquence, contre 28 % pour la mesure syntaxique. Or la méthode en deux étapes traite les contrôles séquentiellement. Lorsque le prédicteur testé est presque une copie d'un contrôle, cette séquence devient instable : l'ordre des opérations influence fortement le résidu et l'estimation n'est plus interprétable comme un effet propre.

La résolution. Je suis passée à un *modèle joint* estimant simultanément surprise et contrôles ; le coefficient de la surprise y est par construction son effet à contrôles constants. J'ai ensuite conçu une figure de diagnostic isolant le rôle de la fréquence : entre les deux panneaux, une seule chose varie, la présence de la fréquence dans le modèle.




Figure 1 – Parole lue, surprise LLM. À gauche, sans contrôle de la fréquence, la tendance monte fortement (pente descriptive +0,0022 s/bit). À droite, avec contrôle, elle devient quasi plate (−0,0001 s/bit). Source : données de la mission.

Le résultat est net : sans contrôler la fréquence, le LLM semble prédire la durée ; dès qu'on l'ajoute, l'effet s'évanouit. Son pouvoir prédictif apparent venait donc de la fréquence, non d'une information propre. Cet épisode a produit deux acquis : la méthode d'estimation doit être choisie selon la structure de corrélation entre prédicteur et contrôles, et non appliquée uniformément ; et un résultat surprenant doit d'abord être traité comme une hypothèse de défaut méthodologique.

4.2 Situation 2 : pourquoi la fréquence détruit un effet et pas l'autre, l'EXTRA

L'anomalie apparente. La comparaison demandée était terminée : la surprise syntaxique conservait son effet après contrôle, la surprise LLM le perdait. Mais une objection sérieuse est apparue. *Les deux* surprises sont corrélées à la fréquence. Si le contrôle détruisait tout prédicteur corrélé à la fréquence, il devrait détruire les deux effets. Il manquait une pièce à l'explication.




Figure 2 – Parole lue, lien surprise / fréquence. Chaque point est un mot, la couleur indique la densité. À gauche la surprise syntaxique ($r = -0,53$; $r^2 = 0,28$), nuage large ; à droite la surprise LLM ($r = -0,75$; $r^2 = 0,56$), resserrée autour de la droite. Source : données de la mission.

La figure 2 contient l’indice décisif sous forme qualitative. À droite, connaître la fréquence permet de deviner assez précisément la surprise LLM. À gauche, à fréquence égale, la surprise syntaxique varie encore beaucoup : il subsiste une information que la fréquence n’explique pas. Cette part vaut $1 - r^2$, soit 72 % pour la mesure syntaxique contre 44 % pour le LLM. Le même constat se reproduit sur la parole spontanée (figure 3), ce qui écarte une particularité du corpus lu, et la figure 4 en donne la vue d’ensemble.




Figure 3 – Parole spontanée (12 réunions appariées), lien surprise / fréquence. À gauche la surprise syntaxique ($r = -0,48$; $r^2 = 0,23$), à droite la surprise LLM ($r = -0,63$; $r^2 = 0,40$). Corrélations plus faibles, corpus plus bruité, mais ordre préservé. Source : données de la mission.




Figure 4 – Force du lien surprise / fréquence (valeur absolue de la corrélation) pour les quatre cas. Bleu : mesure syntaxique ; rouge : mesure LLM, systématiquement plus liée à la fréquence. Source : données de la mission.

L’indicateur EXTRA. Pour transformer cette intuition en test, j’ai construit un indicateur appelé l’*EXTRA*. Si la surprise n’agissait sur la durée que via la fréquence, sa corrélation avec la durée serait entièrement prévisible à partir de sa corrélation avec la fréquence et de la corrélation fréquence–durée. Le produit de ces deux corrélations donne la valeur *attendue via la fréquence* ; l’*EXTRA* est l’écart entre l’observé et cet attendu :

$$\text{EXTRA} = r(\text{durée}, \text{surprise}) - \left[r(\text{surprise}, \text{fréquence}) \times r(\text{durée}, \text{fréquence}) \right] \quad (6)$$

Il mesure donc la part du lien surprise–durée non explicable par la fréquence, c’est-à-dire l’effet propre attendu à fréquence contrôlée. Sa prédiction est falsifiable : le signe de l’*EXTRA* doit correspondre au signe du coefficient de la surprise dans le modèle complet.




Figure 5 – À gauche, pour chaque cas, la corrélation attendue via la fréquence (gris) et celle réellement observée (couleur) ; l’écart est l’*EXTRA*. À droite, l’*EXTRA* seul : positif pour la mesure syntaxique, quasi nul ou négatif pour le LLM. Source : calculs sur les données de la mission.

Table 4 – *Décomposition du lien surprise-durée : observé, attendu via la fréquence, EXTRA.*

Cas	Observé r (durée, surprise)	Attendu via fréquence	EXTRA
Syntaxique, parole lue	+0,47	+0,40	+0,07
LLM, parole lue	+0,59	+0,58	+0,01
Syntaxique, AMI (apparié)	+0,23	+0,19	+0,03
LLM, AMI (apparié)	+0,23	+0,26	-0,02

La figure 5 et le tableau ci-dessus montrent que la prédiction est vérifiée dans les quatre cas : EXTRA positif, coefficient positif ; EXTRA nul, coefficient nul. L’anomalie est résolue. La question pertinente n’est pas « la surprise est-elle corrélée à la fréquence ? », puisque les deux le sont, mais « ce qui, dans la surprise, n’est pas de la fréquence, prédit-il encore la durée ? ».

Reste l’interprétation. Pour la mesure syntaxique, la part orthogonale à la fréquence correspond à la difficulté de construction structurale : un mot peut être fréquent tout en arrivant à un endroit grammaticalement inattendu, imposant un rattachement coûteux ou une réanalyse, ce qui l’allonge indépendamment de sa rareté. Pour le LLM, cette part correspond à une prévisibilité lexicale et sémantique fine qui, sur ces données, n’apporte pas d’effet propre. Une illustration fixe l’idée : deux mots de même fréquence et même longueur, l’un à une position attendue, l’autre imposant une réanalyse ; la fréquence ne les distingue pas, mais le second est plus long. Cette différence est exactement ce que mesure l’EXTRA.

Origine de cette analyse. Elle ne figurait pas dans la demande initiale, qui portait sur la comparaison. Elle est née d’une objection identifiée en produisant cette comparaison et qui, non traitée, aurait rendu la conclusion attaquable. C’est l’apport le plus personnel de la mission.

4.3 Situation 3 : un défaut d’appariement détecté tardivement

Lors d’une relecture systématique de la correspondance entre figures et fichiers de données, j’ai constaté que les deux panneaux comparant les mesures sur AMI ne portaient pas sur les mêmes données : la mesure syntaxique couvrait 171 réunions et environ 846 000 mots, la mesure LLM seulement 12 réunions et environ 60 000 mots. Présentée comme un test à conditions égales, la comparaison opposait en réalité deux populations différentes.

La correction a consisté à restreindre la mesure syntaxique aux 12 réunions communes, les deux mesures portant dès lors sur exactement les mêmes 60 285 mots et 48 locuteurs. J’ai simultanément renforcé le test en passant au modèle mixte, comme la structure des données l’exigeait. L’effet est instructif : sur données appariées, le coefficient syntaxique sur AMI passe de +0,00110 à +0,00077 et son intervalle se rapproche de zéro. L’effet reste significatif ($p = 0,028$) mais nettement plus modeste que ne le laissait croire l’analyse non appariée. Sans cette vérification, le rapport aurait surestimé la robustesse du résultat sur

le spontané.

4.4 Ressources mobilisées et organisation face à ces situations

Ressources scientifiques. La situation 1 s’appuie sur la notion de collinéarité et ses conséquences en régression multiple ; la situation 2 sur la décomposition d’une corrélation en effet direct et effet médié, apparentée à l’analyse de médiation ; la situation 3 sur les modèles à effets aléatoires et la non-indépendance des observations groupées (Baayen et al., 2008 ; Barr et al., 2013). La littérature sur les déterminants de la durée (Aylett et Turk, 2004 ; Bell et al., 2003, 2009) a fourni la liste des contrôles, et Demberg et al. (2012) le protocole de comparaison.

Ressources techniques. Travail entièrement mené en Python : pandas pour le traitement et le nettoyage, numpy pour les corrélations, statsmodels pour les régressions ordinaires et les modèles mixtes, matplotlib pour les figures, parselmouth pour l’extraction du pitch dans le segmenteur prosodique, la bibliothèque Transformers pour la surprise neuronale, et une implémentation propre des probabilités de préfixe pour la chaîne syntaxique. Le suivi de versions et le dépôt des livrables ont été assurés par un dépôt Git.

Ressources humaines. Chaque situation a donné lieu à une sollicitation ciblée : arbitrage avec mon tuteur sur le passage au modèle joint plutôt que la publication d’un résultat inversé ; objection soulevée en discussion à l’origine de l’EXTRA, dont la formalisation a été validée avant intégration aux comptes rendus ; échanges avec des collègues sur les exigences d’appariement et la structure des données AMI.

Organisation. La méthode a été identique et volontairement systématique face à chaque blocage : formuler l’anomalie en une phrase vérifiable, construire une figure ou un test isolant une seule cause possible, écarter ou confirmer cette cause, puis documenter la décision et sa justification dans le compte rendu en cours. C’est cette discipline, plus que la maîtrise d’un outil, qui a permis de traiter les trois situations sans laisser de zone d’incertitude.

En clôture de ce chapitre. Ces trois épisodes ont un point commun : chacun a d’abord ressemblé à un résultat, avant de se révéler être un défaut de méthode. Une erreur d’estimation due à la collinéarité, une objection théorique laissée sans réponse, un défaut d’appariement entre corpus. Traités, ils n’ont pas affaibli la conclusion mais l’ont rendue défendable, au prix d’un résultat plus modeste sur la parole spontanée. Les résultats présentés au chapitre suivant intègrent ces trois corrections.

Chapitre 5

Résultats obtenus

Ce chapitre présente les résultats corpus par corpus, d’abord en parole lue puis en parole spontanée appariée, avant de comparer les deux corpus mesure par mesure. Il se termine par l’examen de la validité, de la nouveauté et de l’utilité de ces résultats, puis par leurs

limites.

5.1 Parole lue




Figure 6 – Parole lue, durée brute par décile de surprise. À gauche la surprise syntaxique, à droite la surprise LLM, même échelle. Source : données de la mission.

La figure 6 montre que les deux panneaux montent : plus un mot est surprenant, plus il est long, pour les deux mesures. La montée est régulière pour la mesure syntaxique et plus étirée pour le LLM, dont la surprise atteint des valeurs plus élevées en bits. Ce constat ne départage pas les deux mesures : la durée brute additionne surprise, longueur et fréquence, trois facteurs corrélés.




Figure 7 – Parole lue, durée résiduelle après contrôle (longueur, fréquence, interaction, classe). À gauche la surprise syntaxique, à droite la surprise LLM. Source : données de la mission.

Le contraste apparaît sur la figure 7, et il est net. À gauche, les déciles s’ordonnent autour d’une droite nettement montante : les mots surprenants restent plus longs même à longueur, fréquence et classe égales. À droite, la droite est quasi plate, très légèrement descendante, sans direction interprétable.

Table 5 – Parole lue : effet de la surprise sur la durée, à contrôles constants.

Parole lue	Coefficient (s/bit)	p	IC à 95 %
Surprise syntaxique	+0,00168	$4 \cdot 10^{-10}$	[+0,00115 ; +0,00221]
Surprise LLM (GPT-2)	−0,00022	0,27	[−0,00062 ; +0,00017]

Les chiffres confirment la lecture visuelle. L'effet syntaxique est positif et hautement significatif : chaque bit supplémentaire allonge le mot d'environ 1,7 milliseconde, toutes choses égales par ailleurs. L'effet LLM n'est pas significatif et son intervalle contient zéro : il s'agit d'un effet réellement nul, non d'un effet faible. Ce résultat réplique l'effet de Demberg et al. (2012) sur un corpus différent, avec une implémentation indépendante.

5.2 Parole spontanée

Les résultats portent sur les 12 réunions appariées (60 285 mots, 48 locuteurs) et sont estimés en modèle mixte à intercept aléatoire par locuteur.




Figure 8 – Parole spontanée (12 réunions appariées), durée brute par décile. À gauche la surprise syntaxique, à droite la surprise LLM. Source : données de la mission.

Comme en parole lue, les deux panneaux de la figure 8 montrent : le lien brut est positif pour les deux mesures. Les courbes sont plus agitées, les déciles moins monotones et les barres d'erreur plus larges, ce qui est attendu en conversation spontanée. Ce lien brut ne départage pas davantage les deux mesures.




Figure 9 – Parole spontanée (12 réunions appariées), durée résiduelle après contrôle (longueur, fréquence, classe, débit). À gauche la surprise syntaxique, à droite la surprise LLM. Pentas descriptives. Source : données de la mission.

Table 6 – Parole spontanée appariée : effet de la surprise sur la durée, modèle mixte.

AMI apparié, modèle mixte	Coefficient (s/bit)	p	IC à 95 %
Surprise syntaxique	+0,00077	0,028	[+0,00008 ; +0,00145]
Surprise LLM (GPT-2)	−0,00179	$1 \cdot 10^{-13}$	[−0,00227 ; −0,00132]

La figure 9 et le tableau ci-dessus donnent deux enseignements, qu’il importe d’énoncer sans les embellir. Premièrement, l’effet syntaxique *tient* sur la parole spontanée : le coefficient reste positif et significatif, ce qui est notable sur un corpus bruité, multi-locuteurs et avec des contrôles plus nombreux. Mais il est *modeste*, le coefficient étant faible et l’intervalle passant près de zéro ; c’est une confirmation de tendance, non une démonstration aussi forte qu’en lecture.

Deuxièmement, la surprise LLM présente un coefficient négatif *statistiquement significatif*. Ce n’est pas un effet nul et l’attribuer au bruit serait inexact. Deux mécanismes l’expliquent. D’une part un effet de suppression : la surprise LLM est très collinéaire avec la fréquence ($r \approx -0,63$ sur AMI), et lorsqu’un prédicteur est presque redondant avec un contrôle, maintenir ce contrôle constant peut faire apparaître un résidu de signe opposé, phénomène apparenté au paradoxe de Simpson. D’autre part un effet de domaine : GPT-2, entraîné majoritairement sur de l’écrit, modélise mal la parole spontanée, ce que confirme le test avec un modèle conversationnel. La conclusion défendable est donc : sur le spontané, la surprise LLM n’apporte aucun effet propre *positif*, et le négatif observé s’explique par la collinéarité et le domaine, non par un mécanisme inverse réel.




Figure 10 – Parole spontanée, surprise LLM, avec et sans contrôle de la fréquence. À gauche, sans contrôle, tendance positive ; à droite, avec contrôle, elle s’effondre sous zéro. Source : données de la mission.

La figure 10 montre que le mécanisme observé en parole lue (figure 1) se reproduit à l’identique : le retrait de la seule fréquence suffit à supprimer tout l’effet positif apparent du LLM. L’observer sur deux corpus très différents renforce l’interprétation.

5.3 Comparaison des corpus

On compare enfin les corpus entre eux, mesure par mesure, pour vérifier si le résultat dépend du style de parole. La parole lue est à gauche, la parole spontanée appariée à droite.




Figure 11 – *Surprise syntaxique, durée brute par décile. À gauche la parole lue, à droite la parole spontanée appariée, même échelle. Source : données de la mission.*

Sur la figure 11, les deux panneaux montent. Deux différences apparaissent, attendues : les mots du spontané sont en moyenne plus longs, l’articulation y étant moins régulière, et la courbe est plus agitée. La forme croissante est identique.




Figure 12 – *Surprise syntaxique, durée résiduelle après contrôle. À gauche la parole lue, à droite la parole spontanée appariée. Tendence montante dans les deux corpus. Source : données de la mission.*

La figure 12 est le panneau décisif : après contrôle, la tendance reste montante dans les deux corpus, nette en lecture, plus bruitée mais toujours orientée vers le haut en spontané. L’effet propre de la surprise syntaxique n’est donc pas une particularité de la lecture soignée.




Figure 13 – *Surprise LLM, durée brute par décile. À gauche la parole lue, à droite la parole spontanée appariée. Source : données de la mission.*

Comme pour la mesure syntaxique, les deux panneaux de la figure 13 montent ; à ce stade rien ne distingue les deux mesures, le brut confondant surprise et fréquence.




Figure 14 – *Surprise LLM, durée résiduelle après contrôle. À gauche la parole lue, à droite la parole spontanée appariée. Aucun effet propre positif dans l’un ou l’autre corpus. Source : données de la mission.*

Sur la figure 14, le contraste avec la figure 12 est complet : quasi plate et très légèrement descendante en lecture, franchement descendante en spontané pour les raisons exposées plus haut. Dans aucun corpus la surprise LLM ne conserve d’effet propre positif.

Table 7 – *Synthèse : effet de la surprise sur la durée, à contrôles constants.*

À contrôles constants	Surprise syntaxique	Surprise LLM
Parole lue (régression ordinaire)	+0,00168 ($p = 4 \cdot 10^{-10}$)	−0,00022 ($p = 0,27$; nul)
AMI apparié (modèle mixte)	+0,00077 ($p = 0,028$)	−0,00179 ($p \approx 10^{-13}$; artefact)

L’ensemble des coefficients, y compris ceux des analyses intermédiaires, figure en Annexe D. Le message est cohérent sur les deux corpus : seule la mesure syntaxique conserve un effet propre positif. La différence entre styles de parole porte sur la *force* de l’effet et le niveau de bruit, non sur son sens.

5.4 Validité, nouveauté et utilité

Validité. Elle repose sur quatre garanties construites pendant la mission : la segmentation a été évaluée objectivement contre le texte original ; l’implémentation du calcul de surprise a été validée contre un calcul exhaustif ; les contrôles appliqués sont ceux de la littérature de référence et neutralisent les explications alternatives connues ; la méthode d’estimation a été adaptée à la structure de corrélation des prédicteurs, et la comparaison sur le spontané rendue strictement appariée et testée avec un modèle tenant compte du regroupement par locuteur.

Nouveauté. Trois éléments constituent un apport propre : la comparaison directe, sur les mêmes données et avec les mêmes contrôles, entre une surprise syntaxique incrémentale exacte et une surprise neuronale, configuration peu courante ; la démonstration que la supériorité prédictive apparente du LLM sur la durée est entièrement médiée par la fréquence ; et l’indicateur EXTRA, critère simple et calculable pour anticiper si un prédicteur survivra au contrôle d’un confondant fortement corrélé.

Utilité et usage effectif. Pour le laboratoire, le résultat oriente directement les choix de modélisation : la mesure de difficulté syntaxique n’est pas rendue obsolète par les modèles de langue, car elle capte une information que ces derniers ne fournissent pas dans une forme exploitable pour la durée. Il éclaire aussi le point de départ EEG : l’échec d’une surprise composite ne signifie pas qu’aucune composante n’a d’effet, et la décomposition reste la bonne stratégie.

Cet usage n’est pas hypothétique : il est engagé avant même la fin du stage. Les indices de surprise calculés sur *The Old Man and the Sea* sont transmis à l’équipe de neuro-imagerie du laboratoire pour être testés comme prédicteurs du signal EEG. Quatre indices sont fournis, issus du croisement de deux facteurs identifiés pendant la mission : la nature de la mesure (syntaxique ou LLM) et le contrôle ou non de la fréquence. Ce dernier facteur est directement issu de mes résultats sur la durée, puisque c’est l’analyse du contrôle de la fréquence qui a révélé que les deux mesures ne se comportent pas de la même façon. Le contraste ainsi obtenu doit permettre de séparer, dans la réponse cérébrale, ce qui relève de la structure syntaxique et ce qui relève de la sémantique. Cette approche constitue une alternative à celle de Caucheteux et al. (2021), qui traite la même question de dissociation par manipulation des représentations internes d’un réseau profond, là où la démarche issue de ma mission repose sur des indices explicitement construits et interprétables. Une publication en anglais reprenant ces travaux est en cours de préparation au sein de l’équipe.

Sur le plan matériel, les livrables sont réutilisables en l’état : segmenteur et son évaluation, chaîne de calcul des deux surprises, corpus enrichis mot à mot, scripts de régression et de figures, comptes rendus documentant chaque chiffre. Le détail de ces cinq blocs figure en Annexe A. Un stagiaire suivant peut les reprendre sans reconstruire la chaîne, et l’EXTRA s’applique à d’autres prédicteurs que la surprise.

5.5 Limites

Six limites doivent être énoncées. Le corpus lu repose sur un **narrateur unique**, la robustesse inter-locuteurs en lecture n'est donc pas établie. L'**effet sur le spontané est faible** : significatif mais modeste, avec un intervalle proche de zéro. Le **périmètre LLM sur AMI** est restreint à 12 réunions, ce qui a imposé de limiter toute la comparaison spontanée. Un **seul modèle de langue** a été testé systématiquement, le test conversationnel restant indicatif. La **qualité de la segmentation et du passage** conditionne la surprise syntaxique et reste fragile sur des énoncés spontanés incomplets. Enfin, l'étude établit une **association** à contrôles constants, non une causalité, qui relèverait d'un protocole expérimental contrôlé.

En clôture de ce chapitre. Le résultat central tient dans une phrase : après neutralisation des déterminants connus de la durée, seule la surprise syntaxique conserve un effet propre positif, nettement en parole lue et plus modestement en parole spontanée. Ces limites, énoncées sans les minimiser, dessinent directement les prolongements du chapitre suivant.

Chapitre 6

Prolongements possibles

Les limites énoncées au chapitre précédent ne sont pas des impasses : chacune ouvre une suite identifiable. Ce chapitre présente quatre directions, classées par effort croissant, en précisant à chaque fois ce qui est déjà engagé et qui peut la prendre en charge.

Étendre la mesure LLM à tout le corpus AMI. Prolongement immédiat et peu coûteux, directement réalisable avec les scripts livrés. Calculer la surprise LLM sur les 171 réunions restaurerait la puissance statistique perdue par l'appariement et vérifierait si l'effet syntaxique, aujourd'hui modeste, se confirme.

Reprendre l'analyse avec un modèle adapté à l'oral. Le coefficient négatif sur AMI est attribué en partie au domaine d'entraînement de GPT-2. Conduire l'analyse complète avec un modèle conversationnel, avec la même rigueur, trancherait cette interprétation au lieu de la supposer.

Revenir à la question EEG avec la surprise décomposée. La mission est née de l'échec de la surprise composite sur l'EEG ; disposant d'une composante syntaxique validée et d'un critère pour évaluer son apport propre, il devient possible de reprendre cette analyse en testant les composantes séparément. Ce prolongement est déjà lancé : les quatre indices de surprise calculés sur *The Old Man and the Sea* (syntaxique et LLM, avec et sans contrôle de la fréquence) sont mis à disposition de l'équipe de neuro-imagerie pour être corrélés au signal EEG, tandis que la nature exacte de l'information portée par la surprise LLM fait l'objet d'une analyse parallèle. L'enjeu dépasse la seule réplique : si les indices se comportent différemment vis-à-vis du signal cérébral comme ils se comportent

différemment vis-à-vis de la durée, on disposerait d'une méthode de dissociation entre syntaxe et sémantique fondée sur des mesures explicitement construites, à la différence des approches par manipulation de représentations neuronales internes (Caucheteux et al., 2021). Une publication en anglais est en préparation sur cette base.

Décomposer plus finement et étendre. L'EXTRA syntaxique est interprété comme la difficulté de construction structurale. Cette interprétation pourrait être testée en distinguant les types de coûts : rattachement ambigu, réanalyse, ouverture ou fermeture de constituant. La démarche s'appliquerait ensuite aux pauses, à l'intensité ou aux marqueurs prosodiques, puis à une autre langue.

Les deux premiers prolongements sont accessibles à un stagiaire disposant des livrables ; les deux suivants relèvent plutôt d'un travail doctoral au sein de l'équipe travaillant sur la modélisation du traitement du langage.

En clôture de ce chapitre. Aucune de ces quatre directions ne remet en cause le résultat obtenu : elles le prolongent, en élargissant le périmètre, en changeant de modèle de langue, en changeant de signal cible ou en affinant la mesure. Les deux premières sont immédiatement réalisables avec les livrables transmis, ce qui garantit que le travail ne s'arrêtera pas à la fin du stage.

Chapitre 7

Bilan des apprentissages professionnels

Ce chapitre ne vise pas l'auto-évaluation mais l'identification des compétences transférables acquises pendant la mission, sur le plan de la démarche scientifique d'abord, sur le plan humain et organisationnel ensuite, avant leur mise en perspective professionnelle.

La validité d'un résultat se construit, elle ne se constate pas. Produire un chiffre est rapide ; démontrer qu'il répond à la question posée prend l'essentiel du temps. Sur trois mois, la part consacrée au calcul est faible devant celle consacrée à l'évaluation de la segmentation, à la validation de l'implémentation, au choix des contrôles, au diagnostic des anomalies et à la vérification de la cohérence entre figures et données.

Un résultat contre-intuitif est d'abord une hypothèse de défaut méthodologique. Face à la durée qui diminuait avec la surprise, la réaction utile n'a pas été d'interpréter mais de diagnostiquer. Cette discipline, chercher l'erreur chez soi avant de conclure à la découverte, est transférable à tout contexte où l'on produit des indicateurs.

Décomposer plutôt que subir un indicateur composite. Le tournant de la mission a consisté à refuser d'utiliser la surprise d'un LLM comme une boîte noire et à en isoler une composante. C'est une manière de raisonner applicable bien au-delà de la linguistique : lorsqu'un indicateur agrégé échoue, la question utile est de savoir ce qu'il agrège.

Le choix de la méthode dépend de la structure des données. Appliquer une méthode parce qu'elle a fonctionné ailleurs est une erreur : la méthode en deux étapes

convenait à la mesure syntaxique et pas au LLM, pour une raison identifiable, la collinéarité avec un contrôle ; la régression ordinaire convenait à un narrateur unique et pas à un corpus multi-locuteurs.

La reformulation d'un problème fait partie du travail. La question initiale menait à une réponse littéralement correcte et scientifiquement trompeuse. Identifier qu'une question est mal posée et proposer une reformulation défendable est une compétence d'ingénieur autant que de chercheur.

Sur le plan humain et organisationnel, plusieurs améliorations décisives ne sont pas venues de moi mais d'échanges : contrôle du débit, traitement des disfluences, vigilance sur l'alignement. J'ai appris à identifier quelle question adresser à quel interlocuteur et à préparer ces échanges pour qu'ils soient utiles en peu de temps. Documenter en continu a permis des corrections précoces et rendu possible la vérification finale qui a révélé le défaut d'appariement. Enfin, ce défaut aurait pu être passé sous silence puisqu'il affaiblissait un résultat ; j'ai choisi de corriger, re-tester avec une méthode plus exigeante et présenter la valeur révisée. Cette exigence est le socle de la crédibilité dans un environnement où les résultats sont destinés à être réutilisés.

Mise en perspective. Cette mission m'a montré ce que recouvre le métier d'ingénieur quand le livrable est une connaissance et non un produit. Formuler correctement un problème, construire une chaîne fiable et évaluée à chaque maillon, isoler un effet parmi des facteurs confondus, quantifier une incertitude et défendre un résultat devant des interlocuteurs exigeants : ces compétences sont transposables à tout métier de la donnée, en particulier lorsqu'il s'agit d'établir qu'une variable a un effet propre et non un effet apparent dû à un facteur tiers.

En clôture de ce chapitre. L'apprentissage central de cette mission n'est pas une technique mais une exigence : ne considérer un résultat comme acquis qu'après avoir écarté les explications concurrentes, et documenter cette élimination pour que d'autres puissent la vérifier. C'est ce qui distingue un chiffre produit d'un résultat établi, et c'est ce que je retiens pour la suite de mon parcours.

Conclusion

La mission portait sur une question posée par le Laboratoire Parole et Langage : la prévisibilité fournie par un modèle de langue neuronal remplace-t-elle la prévisibilité structurale pour expliquer la durée des mots ? Cette question est elle-même issue d'un constat d'échec sur les données EEG, qui avait conduit à décomposer la surprise plutôt qu'à l'utiliser en bloc.

La réponse établie est négative et documentée. En parole lue, la surprise syntaxique conserve un effet positif hautement significatif après contrôle des déterminants connus ($+0,00168$ s/bit, $p = 4 \cdot 10^{-10}$), répliquant Demberg et al. (2012), tandis que la surprise LLM perd tout effet dès que la fréquence est contrôlée. Sur la parole spontanée, après

appariement strict et test en modèle mixte, l'effet syntaxique demeure positif et significatif quoique modeste ($+0,00077$, $p = 0,028$), alors que la mesure LLM ne présente aucun effet propre positif.

Au-delà du constat, la mission fournit une explication du mécanisme via l'indicateur EXTRA : ce n'est pas le fait d'être corrélé à la fréquence qui décide du sort d'un prédicteur après contrôle, mais celui de posséder, en plus de la fréquence, une information propre liée à la variable expliquée. La surprise syntaxique la possède, sous la forme de la difficulté de construction structurale ; la surprise LLM, sur ces données et pour cette variable, ne la possède pas.

La conséquence pour le laboratoire est directe : la modélisation de la difficulté grammaticale conserve sa pertinence face aux modèles généralistes, car elle capte une dimension du traitement que ces derniers ne rendent pas exploitable pour l'articulation. Cette conséquence est déjà mise à l'épreuve : les indices produits pendant la mission sont repris par l'équipe pour être confrontés au signal EEG, et une publication en anglais est en préparation. Au-delà de la question initiale sur la durée, le travail fournit ainsi une piste méthodologique pour séparer syntaxe et sémantique à partir de mesures construites et interprétables, ce qui constitue le prolongement le plus prometteur de ce stage.

Bibliographie

Références

- [1] Aylett, M. et Turk, A. (2004). The Smooth Signal Redundancy Hypothesis. *Language and Speech*, 47(1), 31–56.
- [2] Baayen, R. H., Davidson, D. J. et Bates, D. M. (2008). Mixed-effects modeling with crossed random effects for subjects and items. *Journal of Memory and Language*, 59(4), 390–412.
- [3] Barr, D. J., Levy, R., Scheepers, C. et Tily, H. J. (2013). Random effects structure for confirmatory hypothesis testing : Keep it maximal. *Journal of Memory and Language*, 68(3), 255–278.
- [4] Bell, A., Brenier, J. M., Gregory, M., Girand, C. et Jurafsky, D. (2009). Predictability effects on durations of content and function words in conversational English. *Journal of Memory and Language*, 60(1), 92–111.
- [5] Bell, A., Jurafsky, D., Fosler-Lussier, E., Girand, C., Gregory, M. et Gildea, D. (2003). Effects of disfluencies, predictability, and utterance position on word form variation in English conversation. *JASA*, 113(2), 1001–1024.
- [6] Caucheteux, C., Gramfort, A. et King, J.-R. (2021). Disentangling syntax and semantics in the brain with deep networks. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, PMLR 139, 1336–1348.
- [7] Carletta, J. (2007). Unleashing the killer corpus : experiences in creating the multi-everything AMI Meeting Corpus. *Language Resources and Evaluation*, 41(2), 181–190.
- [8] Demberg, V., Keller, F. et Koller, A. (2012). Syntactic surprisal affects spoken word duration in conversational contexts. *Proceedings of EMNLP-CoNLL 2012*, 356–367.
- [9] Hale, J. (2001). A probabilistic Earley parser as a psycholinguistic model. *Proceedings of NAACL 2001*, 1–8.
- [10] Jelinek, F. et Lafferty, J. D. (1991). Computation of the probability of initial substring generation by stochastic context-free grammars. *Computational Linguistics*, 17(3), 315–323.
- [11] Levy, R. (2008). Expectation-based syntactic comprehension. *Cognition*, 106(3), 1126–1177.
- [12] Radford, A., Wu, J., Child, R., Luan, D., Amodei, D. et Sutskever, I. (2019). Language models are unsupervised multitask learners. *OpenAI Technical Report*.
- [13] Shriberg, E. et Stolcke, A. (2004). Prosody modeling for automatic speech recognition and understanding. *Mathematical Foundations of Speech and Language Processing*, Springer, 105–114.
- [14] Seabold, S. et Perktold, J. (2010). Statsmodels : Econometric and statistical modeling with Python. *Proceedings of the 9th Python in Science Conference*, 92–96.
- [15] Stolcke, A. (1995). An efficient probabilistic context-free parsing algorithm that computes prefix probabilities. *Computational Linguistics*, 21(2), 165–201.

- [16] van Heuven, W. J. B., Mandera, P., Keuleers, E. et Brysbaert, M. (2014). SUBTLEX-UK : A new and improved word frequency database for British English. *Quarterly Journal of Experimental Psychology*, 67(6), 1176–1190.
- [17] Wolf, T. et al. (2020). Transformers : State-of-the-art natural language processing. *Proceedings of EMNLP 2020 : System Demonstrations*, 38–45.

Annexe A : Chaîne de traitement et livrables logiciels

Chaîne livrée en cinq blocs réutilisables indépendamment, citée au Chapitre 5.

Bloc	Fonction	Sortie
Segmenteur prosodique	Pause, allongement final et reset de pitch normalisés en score z , puis règles morphosyntaxiques	Corpus segmenté en phrases
Évaluation du segmenteur	Alignement sur le texte original, précision, rappel, F_1 , comparaison à Whisper	Rapport d'évaluation
Surprise syntaxique	Analyse en constituants, probabilités de préfixe, surprise incrémentale	Corpus enrichi (surprise syntaxique)
Surprise LLM	Probabilités GPT-2, réalignement des sous-unités	Corpus enrichi (surprise LLM)
Analyse et figures	Régressions, modèles mixtes, corrélations, EXTRA, déciles	Résultats et figures du rapport

Annexe B : Formulation des modèles statistiques

Parole lue (régression linéaire ordinaire) :

$$\text{durée} \sim \text{longueur} \times \text{fréquence} + \text{classe} + \text{surprise}$$

Parole spontanée (modèle mixte à intercept aléatoire par locuteur) :

$$\text{durée} \sim \text{longueur} \times \text{fréquence} + \text{classe} + \text{débit} + \text{surprise} + (1 \mid \text{locuteur})$$

Indicateur EXTRA :

$$\text{EXTRA} = r(\text{durée}, \text{surprise}) - r(\text{surprise}, \text{fréquence}) \times r(\text{durée}, \text{fréquence})$$

Dans chaque modèle, le coefficient de la surprise est l'effet d'un bit supplémentaire sur la durée du mot, en secondes, à valeurs constantes des autres variables.

Annexe C : Résultats détaillés

Cette annexe rassemble l'ensemble des valeurs produites par la mission, y compris celles qui ne sont pas reprises dans le corps du rapport. Elle est citée au Chapitre 5.

C.1 Effet de la surprise sur la durée, tous cas. Coefficient de la surprise, en secondes par bit, à contrôles constants.

Corpus	Mesure		Coefficient	p	IC à 95 %
Parole lue (MCO)	Syntaxique		+0,00168	$4,2 \cdot 10^{-10}$	[+0,00115 ; +0,00221]
Parole lue (MCO)	LLM		−0,00022	0,27	[−0,00062 ; +0,00017]
AMI (mixte)	apparié	Syntaxique	+0,00077	0,028	[+0,00008 ; +0,00145]
AMI (mixte)	apparié	LLM	−0,00179	$1,0 \cdot 10^{-13}$	[−0,00227 ; −0,00132]
AMI (MCO)	apparié	Syntaxique	+0,00069	0,050	[+0,00000 ; +0,00137]
AMI (MCO)	apparié	LLM	−0,00186	$1,2 \cdot 10^{-14}$	[−0,00234 ; −0,00139]
AMI (MCO)	complet	Syntaxique	+0,00110	$8,5 \cdot 10^{-32}$	[+0,00092 ; +0,00128]

Les trois dernières lignes documentent les analyses intermédiaires évoquées en section 4.3. La comparaison entre AMI complet et AMI apparié montre l’effet de la correction du périmètre, et la comparaison entre modèle mixte et moindres carrés ordinaires (MCO) sur les mêmes données appariées montre l’effet du changement de modèle.

C.2 Corrélations utilisées pour le calcul de l’EXTRA.

Cas	$r(\text{durée, surprise})$	$r(\text{surprise, fréq.})$	Attendu	EXTRA
Syntaxique, lue	+0,470	−0,525	+0,404	+0,066
LLM, lue	+0,586	−0,746	+0,577	+0,009
Syntaxique, AMI apparié	+0,228	−0,476	+0,194	+0,034
LLM, AMI apparié	+0,234	−0,630	+0,257	−0,023

La corrélation entre durée et fréquence vaut −0,407 sur AMI apparié. L’attendu est le produit des deux corrélations, l’EXTRA la différence entre l’observé et cet attendu.

C.3 Évaluation du segmenteur prosodique. Sur alignement mot à mot, tolérance ± 1 mot : 780 frontières proposées pour 653 frontières réelles, précision 0,70, rappel 0,84, F_1 0,76. Whisper, sur le même corpus : 725 frontières proposées, précision 0,79, rappel 0,88, F_1 0,83.

Annexe D : Périmètre des données analysées

Corpus	Mesure	Mots	Locuteurs
Parole lue (20 fichiers)	Syntaxique	10 672	1
Parole lue (20 fichiers)	LLM	11 413	1
Parole spontanée, 12 réunions appariées	Syntaxique	60 285	48
Parole spontanée, 12 réunions appariées	LLM	60 285	48

Les effectifs de la parole lue diffèrent légèrement entre mesures, en raison des mots pour lesquels l'une ou l'autre n'a pu être calculée (analyse syntaxique indisponible, ou mot absent du vocabulaire aligné). Sur le spontané, l'appariement décrit en section 4.3 garantit un périmètre strictement identique.